# Spark运维管理

www.huawei.com





- 学完本课程后,您将能够:
  - 熟悉Spark安装目录结构
  - □ 熟悉Spark日志目录结构
  - □ 熟悉Spark相关进程
  - □ 掌握Spark对开发工具进行测试方法
  - □ 掌握Spark常见问题及定位



- 1. Spark安装目录结构
- 2. Spark日志目录结构
- 3. 维护命令与参数
- 4. 常见问题与定位

#### 安装目录介绍

Spark组件主要文件安装目录:

{BIGDATA\_HOME}/FusionInsight\_V100R002C60/FusionInsight-Spark-1.5.1/spark

目录路径	目录说明
bin	Spark任务运行脚本目录
RELEASE	Spark社区版本信息
conf	Spark配置文件目录
lib	Spark依赖包目录
scripts	Spark脚本
LICENSE	Licence
NOTICE	声明文件
README.txt	Spark介绍文件
sbin	Spark服务启动、停止等脚本目录
version.properties	FusionInSight构建Spark组件的版本信息



- 1. Spark安装目录结构
- 2. Spark日志目录结构
  - 服务日志介绍
  - **。** Spark任务日志介绍
- 3. 维护命令与参数
- 4. 常见问题与定位



## 服务日志介绍

Spark组件服务日志目录: /var/log/Bigdata/Spark/

日志名称	日志说明
JDBCServer.log	JDBCServer服务进程日志,如果服务异常请检查该日志
JobHistory.log	<b>JobHistory</b> 服务进程日志,如果服务异常请查看该日志
Jdbc-state.check.log	每隔一段时间会对 <b>JDBC</b> 的状态进行检查。该日志记录检 查任务输出的信息
Jdbcserver-omm-进程ID- gc.log	Jdbc服务的GC日志。如果jdbc重启,会根据进程ID重新记录一个日志。默认保存10次进程重启的日志。每个进程日志默认保存10份GC日志,一份日志最大10MB。
Jobhistory-omm-进程ID- gc.log	JobHistory服务的GC日志。保存逻辑同jdbcserver的GC日志。

# 服务日志介绍

日志名称	日志说明
prestart.log	服务进程启动前,会调用预启动。日志记录预 启动的输出结果
spark-availability-check.log	Spark启动时,会对服务状态进行检查,该日志 记录检查相关输出结果
spark-omm- org.apache.spark.deploy.history.H istoryServer-1-机器名.out	JobHistory进程启动脚本的输出结果
spark-omm- org.apache.spark.sql.hive.thriftse rver.om.ha.HiveThriftServer2Shell -1-机器名.out	JDBCServer进程启动脚本的输出结果
spark.log	Spark安装时输出的日志信息



- 1. Spark安装目录结构
- 2. Spark日志目录结构
  - 服务日志目录介绍
  - □ Spark任务日志介绍
- 3. 维护命令与参数
- 4. 常见问题与定位

### Spark任务日志介绍

#### Spark运行时日志查看

提交Spark后,如果想查询Spark任务的运行情况。 在 "服务管理" > "Yarn" > "ResourceManager(主)",打开YARN的WebUI界面。点击该任务的 ApplicationMaster超链接,打开Spark运行日志界面。





### Spark任务日志介绍

#### 通过JobHistory分析运行日志

如果Spark任务运行完成,需要对任务进行日志分析。在 "服务管理" > "Spark",点击 JobHistory打开Spark的WebUI,点击Application的超链接,打开任务相关日志。



Event log directory: hdfs://hacluster/sparkJobHistory

Showing 1-20 of 1525

App ID	App Name	Started
application_1458897636862_1488-part1	queries-sql99/query_20.sql	2016/04/01 09:45:00
application_1458897636862_1487-part1	queries-sql99/query_19.sql	2016/04/01 09:40:58
application_1458897636862_1486-part1	queries-sql99/query_18.sql	2016/04/01 09:38:05
application_1458897636862_1485-part1	queries-sql99/query_17.sql	2016/04/01 09:34:28
application_1458897636862_1484-part1	queries-sql99/query_16.sql	2016/04/01 09:32:29
application_1458897636862_1483-part1	queries-sql99/query_15.sql	2016/04/01 09:30:35
application_1458897636862_1482-part1	queries-sql99/query_14.sql	2016/04/01 09:29:22
application_1458897636862_1481-part1	queries-sql99/query_13.sql	2016/04/01 09:27:17

#### 日志收集

• FusionInsight HD提供了简便的日志收集方法,在 "系统管理" > "日志下载" > "服务"。可以设置并下载在一定时间段内的相关日志。界面如下图:

选择服务		×
LdapClient		
LdapClient		
LdapServer		
LdapServer		
■ Manager		
Controller	Core	NodeAgent
OmmAgent	OmmServer	OmsKerberos
OmsLdapServer	□ OS	☐ Patch
☐ Tomcat	Upgrade	
■ Mapreduce		
JHSAudit	JobHistoryServer	
✓ Spark		
✓ Spark		·

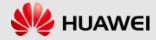


- 1. Spark安装目录结构
- 2. Spark日志目录结构
- 3. 维护命令与常见检查动作
- 4. 常见问题与定位



FusionInsight Spark任务均提交在Yarn上。任务的维护命令依赖于Yarn。输入yarn application可以看到相关维护命令:

usage: application	
-appStates <states></states>	Works with -list to filter applications
	based on input comma-separated list of
	application states. The valid application
	state can be one of the following:
	ALL, NEW, NEW SAVING, SUBMITTED, ACCEPTED, RUN
	NING, FINISHED, FAILED, KILLED
-appTypes <types></types>	Works with -list to filter applications
	based on input comma-separated list of
	application types.
-help	Displays help for all commands.
-kill <application id=""></application>	Kills the application.
-list	List applications. Supports optional use
	of -appTypes to filter applications based
	on application type, and -appStates to
	filter applications based on application
	state.
-movetoqueue <application id=""></application>	Moves the application to a different
	queue.
-queue <queue name=""></queue>	Works with the movetoqueue command to
- "	specify which queue to move an
	application to.
-status <application id=""></application>	Prints the status of the application.



用spark-submit提交一个任务,验证一个Spark功能可用:

- 1、source bigdata\_env,并且kinit一个用户进行认证
- 2、输入命令:spark-submit --class
  org.apache.spark.examples.SparkPi --master yarn-client -executor-cores 2 --executor-memory 2G --num-executors 5
  /客户端/Spark/spark/lib/spark-examples\_2.10-1.5.1.jar
  1000

如果结果输出Pi is roughly 3.14150784(值可能浮动),证明spark可用。

用spark-shell提交一个任务,验证一个spark-shell功能可用:

- 1、source bigdata env, 并且kinit一个用户进行认证
- 2、输入命令spark-shell --master yarn-client 进入客户端
- 3、输入命令val rdd = sc.textFile("HDFS上面任意txt文件")
- **4**、执行rdd.count()

如果能正确输出文件的行数结果,证明spark-shell功能可用。

用spark-beeline提交一个任务,验证JDBCServer服务功能可用:

- 1、source bigdata\_env,并且kinit一个用户进行认证
- 2、输入命令spark-beeline连接Spark客户端
- 3、如果default库存在表数据,执行show tables; 查看返回是否正常
- 4、执行select \* from 表名 limit 10; 查看返回结果是否正常

如果结果均正常,证明JDBCServer服务功能可用。

用spark-sql提交一个任务,验证spark-sql功能可用:

- 1、source bigdata\_env,并且kinit一个用户进行认证
- 2、输入命令spark-sql --master yarn-client连接Spark客户端
- 3、如果default库存在表数据,执行show tables; 查看返回是否正常
- 4、执行select \* from 表名 limit 10; 查看返回结果是否正常如果结果均正常,证明spark-sql功能可用。





- 1. Spark安装目录结构
- 2. Spark日志目录结构
- 3. 维护命令与常见检查动作
- 4. 常见问题与定位

## 常见问题1

	Driver端提示executor memory超限
现象描述	内存超限导致提交Spark任务失败,日志中报如下错误: ERROR SparkContext: Error initializing SparkContext. java.lang.lllegalArgumentException: Required executor memory (10240+1024 MB) is above the max threshold (6144 MB) of this cluster!
原因分析	申请的executor memory超过YARN的限制。
解决方案	此时可通过修改yarn的配置,提高对container的限制。如可通过调整yarn.scheduler.maximum-allocation-mb参数的大小,可控制启动的executor的资源,修改之后要重启下yarn服务。配置修改方法:登录Flweb页面,点击Service->Yarn->Configuration->"将Type修改由Basic为ALL"->"在Search栏输入yarn.scheduler.maximum-allocation-mb"修改参数并保存重启服务。

## 常见问题2

	Spark任务访问HBase,认证异常
现象描述	内存超限导致提交Spark任务失败,日志中报如下错误: ERROR SparkContext: Error initializing SparkContext. java.lang.lllegalArgumentException: Required executor memory (10240+1024 MB) is above the max threshold (6144 MB) of this cluster!
原因分析	申请的executor memory超过YARN的限制。
解决方案	此时可通过修改yarn的配置,提高对container的限制。如可通过调整yarn.scheduler.maximum-allocation-mb参数的大小,可控制启动的executor的资源,修改之后要重启下yarn服务。配置修改方法:登录FusionInsight Web页面,点击服务管理->Yarn->服务配置->将"参数类别"由"基础配置"改为"全部配置"->在搜索栏输入"yarn.scheduler.maximum-allocation-mb"修改参数并保存重启服务。

# ② 习题

- 判断题
  - 1. Spark任务日志会自动归档。 (T or F)
  - 2. Spark任务运行时,需要到JobHistory上查看任务的日志(T or F)
- 多选题
  - 1. 下列哪些服务,不是Spark依赖的服务? ( )
  - **A.YARN**
  - **B.Flume**
  - **C.HDFS**
  - **D.Loader**

#### 思考题

- 使用Spark-beeline创建一张学生表,要求有字段学生编号、 学生姓名,并可以执行计算查询
- 使用spark-submit提交样例工程样例算法PI
- 查看刚才提交任务PI的历史任务日志,查看启动了哪些执行 器,分别耗时多久
- 如何杀死一个正在运行的spark任务



#### 本章总结

- 本章主要介绍了:
  - □ 如果服务启动失败,应该查看何处的日志
  - □ 如果服务出现异常,应该查看何处的日志
  - <sup>ロ</sup> 如何提交一个spark任务
  - <sup>□</sup> 如何提交一个spark-sql
  - <sup>□</sup> 如何分析**spark**任务日志
  - <sup>□</sup>解决常见的**spark**问题

# Thank you

www.huawei.com